



UNIFACS



UNIFACS

NEXUS

Pipeline ETL e Relatório Analítico de E-commerce

Projeto Desenvolvido para Avaliação A3 - Análise de Dados e Big Data

Nome do Integrante	Registro Acadêmico (RA)
Arthur Andrade Silva	12724119792
Eduardo de Andrade do Bomfim Júnior	12724142791
Maria Julia Rodrigues Pereira	1272324889
Tais Lisboa Leite	1272320035
Valentin Eduardo Carvalho Bispo dos Santos	1272415745

Fase 1: Processo de ETL e Qualidade de Dados

1. Extração

As fontes de dados selecionadas estão enquadradas na área de E-commerce, cumprindo o requisito de negócio estabelecido. O processo documentado de extração foi realizado por meio de automações em Python, utilizando:

- Dataset Olist (Kaggle): Arquivos CSV massivos contendo históricos de pedidos, itens, pagamentos, avaliações, produtos e clientes. Extraídos via Kaggle API (script `kaggle_download.py`).
- Brasil API (Feriados): Fonte JSON consumida via requisições REST (script `extract_external.py`) para coletar feriados nacionais de 2016 a 2018, enriquecendo a análise de sazonalidade.



UNIFACS



UNIFACS

- IBGE API: Fonte JSON consumida para coletar metadados de estados e regiões do Brasil (script `extract_ibge_locations.py`), permitindo o agrupamento logístico correto.

2. Transformação

A transformação dos dados (script `build_analytics.py`) incluiu a junção de 10 tabelas distintas e a criação de variáveis analíticas cruciais. As decisões tomadas foram: [cite: 5]

- **Enriquecimento Espacial:** A geolocalização foi agregada pela média das coordenadas por prefixo de CEP para evitar duplicidade de registros que causariam explosão na junção (produto cartesiano). [cite: 5]
- **Criação de Variáveis Analíticas:** Foram calculadas do zero as colunas `delivery_days`, `estimated_days`, `late_days` e `is_late` para viabilizar a análise precisa do desempenho logístico. [cite: 5]
- **Fórmula de Haversine:** Implementada para calcular a distância geodésica em KM entre vendedores e clientes (coluna `distance_km`), insumo fundamental para as correlações de atraso. [cite: 5]

3. Tratamento de Dados Nulos e Vazios

Em vez de simplesmente deletar registros incompletos — o que causaria perda de histórico financeiro —, o pipeline implementou regras rígidas de Governança de Dados para tratar campos vazios de forma estratégica:

- **Preservação de Pedidos Não Entregues:** As colunas logísticas ligadas à entrega ao cliente apresentam 2,98% de valores nulos (pedidos ainda em trânsito ou cancelados). [cite: 5] Esses registros foram preservados para não impactar os números de faturamento total, mas os campos matemáticos dependentes da entrega permanecem como nulos intencionais para evitar distorções nas médias operacionais. [cite: 5]
- **Substituição por Identificadores Padrão:** Campos de texto vazios (como categorias ausentes ou regiões de rotas não identificadas devido a cadastros antigos) foram preenchidos via código com valores padrão como "unknown" ou "Unknown" para evitar erros em agrupamentos analíticos futuros.
- **Nulos Aceitáveis por Desconexão de CEP:** A coluna `distance_km` possui 1,27% de valores nulos devido a pequenos descompassos entre os CEPs das tabelas originais.



UNIFACS



UNIFACS

[cite: 5] Forçar coordenadas fictícias jogaria os cálculos para o mar, logo, mantiveram-se vazios para preservar a pureza estatística das análises de distância. [cite: 5]

4. Carga e Armazenamento

Os dados tratados foram estruturados em uma base analítica unificada desnormalizada denominada orders_analytics.csv. [cite: 5] Justificativa da decisão: A escolha por exportar uma "One-Big-Table" em formato CSV foi feita para garantir o consumo imediato e otimizado por ferramentas de Business Intelligence (como Power BI) ou scripts de visualização (Seaborn), eliminando a necessidade de relacionamentos complexos no front-end. [cite: 5]

Fase 2: Análise Exploratória e Descritiva (EDA)

1. Visão Geral da Qualidade dos Dados

Antes de iniciar a exploração, o processo de ETL consolidou múltiplas fontes (Orders, Customers, Items, Geolocation, etc.) em uma base analítica única. O relatório de qualidade aponta uma base robusta:

- **Volume Processado:** A base final orders_analytics.csv contém 99.441 pedidos e 45 colunas explicativas.
- **Integridade:** Não foram detectados pedidos duplicados ou entregas com prazo negativo (0%).
- **Compleitude Logística:** 96.476 pedidos possuem data de entrega validada ao cliente. O percentual de nulos na coluna order_delivered_customer_date é de apenas 2,98% (pedidos cancelados, perdidos ou em trânsito).
- **Taxa de Atraso Global:** Em média, 8,11% das entregas foram realizadas fora do prazo estimado.



UNIFACS



UNIFACS

2. Estatística Descritiva

A tabela abaixo apresenta as medidas de tendência central e dispersão das variáveis numéricas primárias do negócio, calculadas após o tratamento de dados:

Métrica	Contagem	Média	Desvio Padrão (std)	Mínimo	1º Quartil (25%)	Mediana (50%)	3º Quartil (75%)	Máximo
Valor dos Produtos (R\$)	98.666	137,75	210,65	0,85	45,90	86,90	149,90	13.440,00
Valor do Frete (R\$)	98.666	22,82	21,65	0,00	13,85	17,17	24,04	1.794,96
Tempo de Entrega (Dias)	96.476	12,56	9,55	0,53	6,77	10,22	15,72	209,63
Distância Estimada (KM)	98.175	601,65	595,20	0,00	185,72	433,79	799,34	8.677,91

Insights Descritivos:

- **Assimetria Financeira:** A média do valor dos produtos (R\$ 137,75) é bem superior à mediana (R\$ 86,90), indicando que poucos pedidos de altíssimo valor (até R\$ 13.440,00) puxam a média para cima.
- **Desafio Logístico Extremo:** A entrega média ocorre em 12,5 dias, porém o desvio padrão elevado (9,5 dias) e o valor máximo de 209 dias apontam para graves quebras de serviço em rotas específicas.




UNIFACS



UNIFACS

3. Padrões e Visualizações (EDA)

3.1. Distribuição Logística



(Referência: hist_tempo_entrega.png)

O Histograma do Tempo de Entrega confirma a assimetria apontada na estatística descritiva. A grande massa de dados (moda) concentra-se entre 5 e 10 dias. Contudo, há uma longa cauda à direita (long tail), demonstrando que uma fatia considerável de clientes espera entre 20 e 60 dias para receber seus pedidos, o que afeta diretamente a percepção de qualidade do serviço.




UNIFACS



UNIFACS

3.2. Dispersão de Custos por Região



(Referência: box_frete_regiao.png)

O Box Plot segmentado por Região do Cliente ilustra a disparidade logística no Brasil. Enquanto a região Sudeste apresenta a menor mediana e a menor variação no valor do frete (a maioria abaixo de R\$ 20,00), as regiões Norte e Nordeste apresentam medianas superiores a R\$ 30,00 e uma vasta quantidade de outliers (valores que fogem do padrão), ultrapassando frequentemente a casa dos R\$ 100,00. Isso evidencia um gargalo claro de infraestrutura ou de malha de distribuição nessas regiões.




UNIFACS



UNIFACS

3.3. Relação Distância vs. Tempo

Relação: Distância (KM) vs Tempo de Entrega (Dias)



(Referência: scatter_distancia_tempo.png)

O Gráfico de Dispersão mapeia a correlação física. Observa-se que a grande densidade de entregas rápidas (menos de 15 dias) ocorre em raios de até 1.000 KM de distância do vendedor. Conforme a distância ultrapassa os 2.000 KM, a nuvem de pontos se espalha verticalmente, consolidando entregas que variam imprevisivelmente de 15 a 75 dias.




UNIFACS



UNIFACS

3.4. Matriz de Correlação Linear



(Referência: heatmap_correlacao.png)

O Heatmap traduziu as relações em coeficientes numéricos (Pearson):

- **Correlação Positiva (Distância e Tempo):** distance_km(distancia em KM) e delivery_days (Dias de entrega) possuem correlação de 0.39, indicando que a distância é



UNIFACS




UNIFACS

um fator relevante para o aumento do prazo, mas não o único (outros fatores como malha viária e parceiros locais influenciam).

- **Correlação Positiva (Distância e Frete):** distance_km (distancia em KM) e total_freight_value (valor total do frete) possuem correlação de 0.31.
- **Correlação Negativa (Satisfação):** O tempo de entrega (delivery_days) possui uma correlação inversamente proporcional com a nota de avaliação do cliente (review_score) em -0.33. Este é o insight mais acionável: atrasos ou demoras longas estão diretamente ligados à queda da nota da loja.

3.5. Comportamento e Tendência de Vendas



(Referência: linha_tendencia_vendas.png)

A Linha de Tendência Temporal exibe o crescimento sustentado do volume de pedidos ao longo de 2017. O ápice do volume ocorre no final de 2017 (novembro/dezembro), indicando o forte efeito de sazonalidade provocado por eventos como Black Friday e festividades de final de ano. A queda brusca no final de 2018 deve-se ao limite temporal de coleta do dataset original.



UNIFACS



UNIFACS

Conclusão da EDA para o Storytelling (Fase 3):

Os dados provam estatisticamente que a operação de E-commerce sofre com a amplitude territorial do país. Aumentos na distância encarecem o frete (concentrando dores no Norte e Nordeste), dilatam o tempo de entrega e, consequentemente, destroem o índice de satisfação do cliente (Review Score). A apresentação para os stakeholders deve focar na resolução da logística regional para proteger a reputação das vendas.

Fase 3: Ética e Governança de Dados

Privacidade e Conformidade (LGPD)

O projeto foi construído respeitando as normativas da Lei Geral de Proteção de Dados (LGPD). As bases brutas (Olist Dataset) já possuem um tratamento nativo de anonimização, onde todos os identificadores pessoais (Nomes, CPFs, Endereços Exatos) foram substituídos por hashes criptográficos únicos. A identidade dos titulares está integralmente protegida.

Postura Ética e Viés Algorítmico

A equipe garante que a análise logística não resultará em práticas discriminatórias. A identificação de rotas ineficientes visa a melhoria do serviço e do investimento em infraestrutura, não a exclusão de regiões. A análise de perfis de compra foi desprovida de marcadores sensíveis.

Fase 5: Planejamento e Execução

As seguintes tecnologias foram consolidadas no pipeline para garantir a reprodutibilidade técnica:

- Linguagem: Python 3.11+.



UNIFACS



UNIFACS

- Bibliotecas: Pandas, Math, Json, Matplotlib, Seaborn.
- Ambiente: Gerenciador UV, integração com Kaggle API, Google COLAB.

Fase 6: Referências

As seguintes referências foram utilizadas:

- <https://servicodados.ibge.gov.br/api/v1/localidades/estados?orderBy=nome>
- <https://servicodados.ibge.gov.br/api/v1/localidades/estados?orderBy=nome>
- <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>